POLITECHNIKA KRAKOWSKA

IM. TADEUSZA KOŚCIUSZKI

WYDZIAŁ FIZYKI MATEMATYKI I INFORMATYKI

KIERUNEK INFORMATYKA

MARIUSZ OKULANIS

Implementacja filtra antyspamowego przy użyciu uczenia maszynowego

Implementation of the anti-spam filter using machine learning algorithms

PRACA INŻYNIERSKA

STUDIA STACJONARNE

Promotor: dr inż. Michał Bereta

Kraków 2014

Spis treści

1 Wstęp

Poczta elektroniczna jest wynalazkiem bardzo ułatwiającym komunikację z ludźmi. Pozwala na natychmiastowy kontakt, ze znajomymi, współpracownikami, nie ponosząc przy tym żadnych kosztów. Ta ostatnia zaleta, łatwo może być również wykorzystana przez spamerów, czyli osoby rozsyłające drogą elektroniczną niechciane wiadomości - spam. Wykorzystują oni wiadomości e-mail między innymi do rozsyłania treści reklamowych.

Istnieje wiele różnych sposobów obrony przed spamem. Tym, któremu poświęcono prace jest stworzenie systemu zdolnego nauczyć się rozróżniać wiadomości spamowe od niespamowych. Do nauki wykorzystano publicznie dostępny korpus wiadomości e-mail [9].

W dalszej części tego rozdziału opisane zostały szczegółowe cele pracy, przybliżone zostało pojęcie uczenia maszynowego i narzędzia z nim związane. Opisano również budowę filtra antyspamowego będącego tematem tej pracy.

W drugim rozdziale przedstawiony został korpus wiadomości, jaki był wykorzystywany przy trenowaniu i testowaniu owego filtra. Przybliżono strukturę wiadomości e-mail, oraz techniczne szczegóły, na które należy zwrócić uwagę przy przetwarzaniu wiadomości. Opisane zostały cechy wiadomości, według których uczyć się będzie filtr oraz mechanizmy, które cechy te przetwarzają, tak aby skorzystać z nich mogły algorytmy uczenia maszynowego.

W rozdziale trzecim opisano algorytmy uczenia maszynowego, proces ich uczenia oraz efekty ich nauki. Przedstawione zostały także mechanizmy związane z ich testowaniem i wizualizacją efektywności. Znalazło się tam również zbiorcze porównanie skuteczności poszczególnych algorytmów.

Rozdział czwarty poświęcony został zagadnieniu integracji tworzonego filtra antyspamowego z klientami poczty elektronicznej. Opisano stworzony protokół komunikacji i zademonstrowana została przykładowa wtyczka do programu pocztowego, dokonująca takiej integracji.

Piąty rozdział poświęcono na podsumowanie pracy i propozycje jej dalszego rozwoju.

1.1 Cel pracy

Celem pracy było stworzenie systemu filtra antyspamowego. Zadaniem systemu jest:

1. Poprawne wczytanie i przetworzenie dowolnej wiadomości e-mail.
2. Nauka klasyfikacji spamu na podstawie danych treningowych.

3. Udostępnienie interfejsu pozwalającego zewnętrznym aplikacjom na sklasyfikowanie e-maili.

Przy klasyfikacji system skupia się przede wszystkim na treści wiadomości. Informacje takie jak adres nadawcy lub adres serwera, z którego wiadomość nadeszła, nie są brane pod uwagę.

1.2 Uczenie maszynowe

Uczenie maszynowe jest dziedziną sztucznej inteligencji. Polega ono na tworzeniu systemów, które na podstawie przykładów są w stanie uczyć się, to znaczy zyskiwać wiedzę poprzez gromadzenie doświadczenia. Umożliwia im to efektywniejsze wykonywanie podobnych zadań w przyszłości [1].

Uczenie maszynowe ma szerokie zastosowanie w różnych aspektach życia, stosuje się je między innymi do:

- rozpoznawania mowy i pisma,
- automatycznego sterowania samochodami,
- klasyfikacji obiektów astronomicznych,
- wykonywania analiz rynkowych.

Wszystkie pomiary wydajności algorytmów, znajdujące się w dalszej części pracy, zostały wykonane na komputerze o parametrach:

- Procesor Intel Core i7 (4 rdzenie),
- 12 GB pamięci RAM.

1.3 Biblioteka scikit-learn

Biblioteka *scikit-learn* [2], znana również pod nazwami *scikits.learn* i *sklearn*, jest open-source'ową biblioteką przeznaczoną dla języka programowania Python. Dostarcza wiele algorytmów uczenia maszynowego do klasyfikacji, regresji i grupowania danych. Prócz tego biblioteka zawiera również funkcje pomocnicze służące między innymi do:

- normalizacji danych,
- kroswalidacji systemów uczących się,
- mierzenia efektywności systemów.

Dla algorytmów takich jak regresja logistyczna i maszyna wsparcia wektorowego *scikit-learn* wykorzystuje zewnętrzne biblioteki *LIBLINEAR* [3] i *LIBSVM* [4], co zapewnia wysoką wydajność obliczeń.

1.4 Elementy projektu

W filtrze antyspamowym, będącym tematem tej pracy, znajdują się następujące elementy:

Parser wiadomości e-mail

Podstawową funkcją parsera jest poprawne wczytanie wiadomości e-mail, w tym celu musi on:

1. Wczytać nagłówki wiadomości.
2. Wczytać ciało wiadomości.
3. Zdekodować ciało wiadomości na podstawie kodowania, i strony kodowej znalezionych w nagłówku.
4. Rozpoznać czy ciało wiadomości jest HTMLem i poprawnie go sparsować.

Na parsowanie HTMLa składa się:

1. Przetworzenie ciała do prostego tekstu (plaintext).
2. Podsumowanie liczby i typów tagów użytych w wiadomości.
3. Podliczenie liczby błędów, które pojawiły się w drzewie wiadomości.

Parser stworzony został w oparciu o moduł *HTMLParser* [5] z biblioteki standardowej języka Python.

Ekstraktor cech

Po wczytaniu wiadomości należy przedstawić zawarte w niej informacje (cechy wiadomości) w formie numerycznej. Ekstraktor zajmuje się takimi zadaniami jak:

1. Zliczenie wystąpień słów w temacie wiadomości.
2. Zliczenie wystąpień słów w ciele wiadomości.

3. Zliczenie wystąpień linków i adresów w ciele wiadomości.

Do zliczania słów wykorzystane zostały narzędzia [6] pochodzące z biblioteki *scikit-learn*.

Klasyfikator

Klasyfikator jest modułem odpowiedzialnym za utworzenie modelu klasyfikatora wiadomości. Wykorzystuje on informacje uzyskane z ekstraktora cech. Znajdują się tutaj funkcje odpowiedzialne za trening oraz testowanie modelu, a także wykonujące pomiar wydajności poszczególnych algorytmów.

Serwer HTTP

Zadaniem serwera jest:

1. Nasłuchiwanie żądań HTTP (ang. *Hypertext Transfer Protocol*) z wiadomościami nadsyłanymi przez programy pocztowe.
2. Sprawdzenie w klasyfikatorze nadesłanej wiadomości.
3. Odesłanie odpowiedzi zawierającej przewidywania klasyfikatora.

Wtyczka do programu pocztowego

W celu demonstracji możliwości integracji filtra antyspamowego z klientami poczty, stworzona została przykładowa wtyczka do programu *Claws Mail* [7].

2 Przetwarzanie wiadomości

Ważnym krokiem w procedurze klasyfikacji spamu jest parsowanie wiadomości e-mail. To w jej treści znajdują się wszystkie informacje wymagane do poprawnego rozpoznania niechcianej wiadomości. Z tego powodu stworzenie sprawnie działającego parsera wiadomości jest bardzo ważne. Protokół e-mail posiada kilka mechanizmów, które przy codziennym korzystaniu z poczty elektronicznej są rzadko spotykane, a które często bywają wykorzystywane przez spamerów, w celu utrudnienia odczytu wiadomości przez filtry antyspamowe.

2.1 Korpus wiadomości

W projekcie wykorzystana została baza wiadomości używana w projekcie *SpamAssasin* [8]. Znajdujące się w niej wiadomości pochodzą z różnych źródeł, są to między innymi publiczne fora, newslettery stron internetowych oraz skrzynki pocztowe osób zaangażowanych w tworzenie korpusu [9]. Wśród znajdujących się w tej bazie e-maili można wyróżnić następujące kategorie:

- **Spam** - wiadomości spamowe, żadne z tych wiadomości nie pochodzą z pułapek na spam - to znaczy - zostały wysłane na adresy e-mailowe służące do normalnej korespondencji.
- **Easy Ham** - wiadomości niespamowe, stosunkowe łatwe do odróżnienia od spamu, rzadziej wykorzystują HTML i nieczęsto zawierają typowo spamowe frazy.
- **Hard Ham** - wiadomości niespamowe, trudniejsze do odróżnienia od spamu, często zawierają błędnie sformatowany HTML, wykorzystują frazy spotykane w spamie.

Tabela 2.1 zawiera informacje na temat liczby wiadomości w poszczególnych kategoriach.

Tabela 2.1. *Liczba wiadomości poszczególnych kategorii znajdujących się w korpusie*

Kategoria	Liczba wiadomości
Easy Ham	3951
Hard Ham	250
Spam	1896
Suma	**6097**

2.2 Budowa wiadomości e-mail

Surowa wiadomość e-mail składa się z dwóch części: nagłówków i ciała. Części te oddzielone są od siebie sekwencją znaków `<CR><LF><CR><LF>` (CR - Carriage Return, LF - Line Feed).

Część nagłówkowa składa z wielu nagłówków w formacie: `Nazwa nagłówka: Wartość nagłówka`. Jeden taki nagłówek może zajmować kilka linijek (każda kolejna linijka musi się rozpoczynać białymi znakami - spacje lub tabulacje). Wielkość znaków w nazwie nagłówka nie ma znaczenia. Listing 2.1 zawiera przykładowy nagłówek.

```
Return-Path: <bduyisj36648@Email.cz>
Delivered-To: yyyy@netnoteinc.com
Received: from tugo (unknown [211.115.78.51]) by mail.netnoteinc.com
    (Postfix) with ESMTP id F40CA1140BA; Fri,  6 Jul 2001 02:03:10 +0000
    (Eire)
Received: from 127.0.0.1 ([202.72.66.134]) by tugo with Microsoft
    SMTPSVC(5.0.2172.1); Fri, 6 Jul 2001 11:00:31 +0900
Message-Id: <Mp9U4NEPd9mpa.8zI7m9NaCf4dlKT-HBhxaL@127.0.0.1>
From: bduyisj36648@Email.cz <bduyisj36648@Email.cz>
Subject: Finally   collecct   your   judgment (71733)
Date: Wed, 16 Aug 2000 17:38:13 -0400 (EDT)
MIME-Version: 1.0
Content-Transfer-Encoding: 7bit
X-Originalarrivaltime: 06 Jul 2001 02:00:32.0843 (UTC) FILETIME=[708F81B0:
    01C105BF]
To: undisclosed-recipients:;
```

Listing 2.1. *Przykładowy nagłówek wiadomości e-mail*

Ciało wiadomości to właściwa zawartość e-maila. Może być ono zapisane zarówno w języku znaczników jakim jest HTML, jak również jako zwykły tekst. Ponadto ciało zapisane jest w konkretnej stronie kodowej. Może również być dodatkowo zakodowane kodowaniem `quoted-printable`.

2.3 Ważne nagłówki

Content-Type

Jedną z podstawowych informacji jaką zawiera ten nagłówek jest typ ciała wiadomości. Najczęściej wykorzystywane są tu:

- `text/plain` - wiadomość zapisana prostym tekstem,
- `text/html` - wiadomość zapisana z użyciem HTML.

E-maile często jednak nie zawierają tych informacji lub celowo opisują je w sposób mylący. Z tego powodu parser nie polega na tej informacji i sam stara się wykryć czy wiadomość zawiera HTML, czy też nie.

Spotyka się również maile wieloczęściowe, przykładowo kiedy w mailu zamieszczone są obrazki lub inne załączniki, albo kiedy mail posiada swoją wersję zarówno w HTMLu i prostym tekście. Wówczas ciało wiadomości podzielone jest na części ciągiem znaków zwanym `boundary` (granica). Wówczas każda z części posiada swoje własne nagłówki i ciało.

Inną ważną informacją zawartą w tym nagłówku jest deklaracja strony kodowej, w której zapisane zostało ciało. Na podstawie tej informacji parser dekoduje tekst wiadomości na swój wewnętrzny format.

Listing 2.2 zawiera przykłady użycia tego nagłówka.

```
Content-Type: text/html;
Content-Type: text/html;    charset=iso-8859-1
Content-Type: text/html; charset="CHINESEBIG5"
Content-Type: text/html; charset="ISO-8859-1"
Content-Type: text/html; charset="US-ASCII"
Content-Type: text/html; charset="Windows-1251"
Content-Type: text/html; charset="euc-kr"
Content-Type: text/html; charset="gb2312"
Content-Type: text/html; charset="ks_c_5601-1987"
Content-Type: text/html; charset="us-ascii"
Content-Type: text/html;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;; (...)
Content-Type: text/html;charset=ks_c_5601-1987
Content-Type: text/plain;
Content-Type: text/plain; Charset = "us-ascii"
Content-Type: text/plain; charset="DEFAULT"
Content-Type: text/plain; charset="DEFAULT_CHARSET"
Content-Type: text/plain; charset="GB2312"
Content-Type: multipart/alternative; boundary="----=_NextPart_000_81109_01C25FF9.832EE820"
Content-Type: multipart/mixed; boundary="=_NextPart_Caramail_0190361032516937_ID"
```

Listing 2.2. *Przykłady wykorzystania nagłówka `Content-Type`*

Content-Transfer-Encoding

Nagłówek ten opisuje jak zakodowane są dane w ciele wiadomości. W przypadku wiadomości e-mail można spodziewać kodowań:

- `7bit` - dane tekstowe zakodowane tylko na 7 bitach (ASCII),
- `8bit` - dane tekstowe zakodowane na 8 bitach (inne strony kodowe),
- `quoted-printable` - dane zakodowane kodowaniem `quoted-printable`,
- `base64` - dane zakodowane za pomocą `base64`.

Listing 2.3 zawiera przykłady wykorzystania tego nagłówka.

```
Content-Transfer-Encoding: 7BIT
Content-Transfer-Encoding: 8bit
Content-Transfer-Encoding: QUOTED-PRINTABLE
Content-Transfer-Encoding: base64
```

Listing 2.3. *Przykłady wykorzystania nagłówka* `Content-Transfer-Encoding`

Subject

W nagłówku tym zapisany jest temat wiadomości. Domyślnie nagłówek ten zawiera tylko znaki ASCII. Jednak tutaj, podobnie jak w ciele wiadomości, spotkać się można z różnymi stronami kodowymi i kodowaniami. Jeśli nagłówek jest dodatkowo zakodowany przyjmuje on postać: `=?strona_kodowa?kodowanie?zakodowany_temat?=`. Zawartość takiego nagłówka składa się z następujących elementów:

- `strona_kodowa` to nazwa strony kodowej, w jakiej zapisany jest temat,
- `kodowanie` to litera `Q` lub `B`, wskazuje to typ użytego kodowania, `Q` to `quoted-printable`, `B` to `base64`,
- `zakodowany_temat` to zakodowany temat wiadomości.

W celu odczytania takiego tematu najpierw dekodowany jest `zakodowany_temat` używając właściwego kodowania, a następnie odczytywany jest, przy pomocy podanej strony kodowej.

```
Subject: Your eBay account is about to expire!
Subject: re: domain registration savings
Subject: Make a Fortune On eBay                        24772
Subject: Save $30k even if you've refi'd          1090
Subject: =?Big5?B?rEKq96SjrE5+fqdPtsykRn5+?=
Subject: =?GB2312?B?NTDUqrvxtcPSu9LazuXHp83yRU1BSUy12Na3tcS7+rvh?=
Subject: =?GB2312?B?0rvN+KGwu92hsczsz8KjrNK71bnM7M/C1qotLS0tMjAwM8TqNNTCMcjVLS00?=
```

Listing 2.4. *Przykłady wykorzystania nagłówka* `Subject`

W listingu 2.4 można zauważyć, że w końcówkach niektórych tematów pojawiają się dodatkowe nieznaczące znaki. Jest to technika używana przez spamerów mająca na celu zmylenie prostych filtrów antyspamowych, które sprawdzają czy dana wiadomość jest spamem bądź na podstawie prostego porównania tematu wiadomości z zebraną wcześniej bazą spamu.

2.4 Dekodowanie ciała wiadomości

W wiadomościach e-mail spotkać się można z dwoma różnorodnymi kodowaniami (nie licząc kodowań podstawowych `7bit` i `8bit`). Jedno z nich to `quoted-printable`. Jest to stosunkowo proste kodowanie, które zapisuje bajty o wartości większej od 127, bajty będące kodami sterującymi ASCII oraz znak = zapisując każdy z tych bajtów jako wartość szesnastkową poprzedzoną znakiem =. Ponieważ zakodowane są tylko pojedyncze znaki kodowanie to jest proste do zdekodowania.

W listingu 2.5 zamieszczono fragment ciała wiadomości zakodowanego z wykorzystaniem `quoted-printable`.

```
<html><body><center>

<table bgcolor=3D"663399" border=3D"2" width=3D"999" cellspacing=3D"0" cel=
lpadding=3D"0">
  <tr>
    <td colspan=3D"3" width=3D"999"> <hr><font color=3D"yellow">
<center>
<font size=3D"7">
<br><center><b>Get 12 FREE VHS or DVDs! </b><br>
<table bgcolor=3D"white" border=3D"2" width=3D"500">
```

Listing 2.5. *Fragment ciała wiadomości e-mail zakodowany przy użyciu* `quoted-printable`

Drugim spotykanym kodowaniem jest `base64`. Jest to inny rodzaj kodowania, koduje się za jego pomocą już nie pojedyncze znaki a cały blok danych. W niektórych wiadomościach zdarza się spotkać z sytuacją, kiedy tylko początek ciała jest zakodowany jako `base64`, natomiast reszta tekstu zapisana jest prostym tekstem. Z tego powodu do wyznaczenia części wiadomości, która jest zakodowana wykorzystane zostało wyrażenie regularne, które dopasowywane jest do ciała. Wyrażenie to zamieszczone jest w listingu 2.6. Tekst "Ala ma kota" zapisany w kodowaniu `base64` znajduje się w listingu 2.7.

```
RE_BASE64 = re.compile('(?:(?:[a-zA-Z0-9+/=]+)[\n]?)+')
```

Listing 2.6. *Wyrażenie regularne znajdujące tekst będący wynikiem kodowania* `base64`

```
QWxhIG1hIGtvdGE=
```

Listing 2.7. *Tekst "Ala ma kota" zapisany z użyciem kodowania* `base64`

Aby wiadomość mogła być prawidłowo wyświetlona musi zostać wczytana przy pomocy odpowiedniej strony kodowej. Wymagana strona kodowa zadeklarowana jest w nagłówku

`Content-Type` jako `charset`. Przy przetwarzaniu tekstu może się zdarzyć sytuacja, że bajt, który jest przetwarzany nie został przewidziany w stronie kodowej. W takim przypadku bajt taki jest ignorowany.

2.5 Przetwarzanie HTML

Jeśli ciało wiadomości zostanie rozpoznane jako HTML zostaje podjęta akcja parsowania go. Proste podejście do tego problemu (czyli zbudowanie drzewa tagów) nie jest tutaj skuteczne. Powodem tego jest ogromna liczba błędów występujących w mailach. Najczęściej spotykane to:

- brak domknięć części otwartych tagów,
- "zakleszczanie" tagów (np. `<b><i>Tekst</b></i>`),
- brak elementu `<html>` w dokumencie.

Z tego powodu wykorzystany został parser, który wczytuje kolejne otwarcia tagów, prosty tekst między nimi i zamknięcia tagów. Na podstawie napotkanych otwarć i zamknięć tworzy on stos tagów, ignoruje jednak przy tym wszelkie niewłaściwe domknięcia (zapisuje jednak ich liczbę). Zwykły tekst pomiędzy tagami zostaje zapisany do bufora z prostym tekstem.

Prócz ekstrakcji tekstu z dokumentu HTML powyższy parser zbiera również statystyki na temat pokrycia tekstu przez tagi (np. ile liter w dokumencie było obłożone tagami pogrubienia), oraz zlicza liczbę błędów napotkanych przy przetwarzaniu struktury HTML.

2.6 Wiadomości wieloczęściowe

Jak już wcześniej wspomniano, niektóre wiadomości mają formę wieloczęściową. Takie e-maile rozpoznać można po typie `multipart/` zawartym w nagłówku `Content-Type`. Wówczas nagłówek ten zawiera również wartość `boundary`, która posłuży do podzielenia wiadomości. Przykładowo jeśli nasze `boundary` przyjmuje wartość `QWERTY` to separatory w dokumencie mają wartość `--QWERTY`. Wyjątkiem jest tu ostatni separator, jego wartość to `--QWERTY--`. Wszystkie informacje zawarte przed pierwszym i za ostatnim separatorem zostają zignorowane.

Następnie wszystkie znalezione w ten sposób części wiadomości zostają ponownie sparsowane (traktowane są jako osobne wiadomości) a następnie ponownie zebrane w całość (teksty zostają połączone, a statystyki zsumowane).

Może się również zdarzyć sytuacja, że część wiadomości również jest wiadomością wieloczęściową. Z tego powodu wykorzystane zostało rozwiązanie rekurencyjne, które łatwo radzi sobie z takim problemem.

Listing 2.8 zawiera przykładową wiadomość wieloczęściową. Wartość `boundary` dla niej to `BoundaryOfDocument`.

```
This is a multi-part message in MIME format.

--BoundaryOfDocument
Content-Type: text/plain
Content-Transfer-Encoding: 7bit

FREE CD-ROM LESSONS
http://isis.webstakes.com/play/Isis?ID=89801

1. Choose from 15 titles
2. Learn new skills in 1 hour
3. Compare at $59.95
4. Quick, easy and FREE!

(...)

--BoundaryOfDocument
Content-Type: text/html
Content-Transfer-Encoding: 7bit

<META HTTP-EQUIV="Content-Type" CONTENT="text/html;charset=iso-8859-1">
<!DOCTYPE HTML PUBLIC "-//W3C//DTD HTML 4.0 Transitional//EN">
<HTML><HEAD><TITLE>Untitled Document</TITLE>
<META content="text/html; charset=iso-8859-1" http-equiv=Content-Type>
</HEAD>
<BODY bgColor=#ffffff><CENTER>
<TABLE align=center border=0 cellPadding=0 cellSpacing=0 width=500>

(...)

--BoundaryOfDocument--
```

Listing 2.8. *Przykładowa wiadomość wieloczęściowa*

2.7 Istotne cechy wiadomości

Najważniejszym krokiem podczas tworzenia systemu antyspamowego było pobranie odpowiednich cech z wiadomości. Informacje zawarte w wiadomości, na które zwraca uwagę filtr, to przede wszystkim temat wiadomości i jej treść. Innymi ważnymi cechami jest pokrycie tekstu wiadomości tagami wyróżniającymi. Ma to na celu zwrócenie szczególnej uwagi na wiadomości gdzie spora część tekstu miała na celu przykucie uwagi odbiorcy.

Większość wykorzystanych w tej pracy algorytmów uczenia maszynowego (wszystkie oprócz drzew decyzyjnych) wymaga, aby ich dane wejściowe były danymi numerycznymi. Nie jest to problemem dla danych takich jak liczba użytych tagów, czy procentowe pokrycie tekstu danym tagiem. Jednakże, danych tekstowych nie można przekazać do algorytmów w bezpośredniej formie. W tym celu zamieniane są na dane numeryczne, proces ten zwany jest wektoryzacją. Polega on na zliczeniu wystąpień `N` najczęściej występujących słów, we wszystkich przetwarzanych e-mailach. Efektem takiego działania będzie macierz o wymiarze $M \times N$, gdzie M jest liczbą przetwarzanych tekstów. Macierz ta będzie macierzą rzadką. Wartość N, będąca liczbą najpopularniejszych słów jakie zliczamy, była dobierana eksperymentalnie, testowane były różne warianty. Wektoryzacja ta została zastosowana do przetworzenia tematów wiadomości.

Do przetworzenia ciał wiadomości zastosowana została inna forma zliczania słów, mianowicie TF-IDF (ang. TF - term frequency, IDF - inverse document frequency). Użycie tej techniki sprawia, że mniejsza waga zostaje przypisana do słów popularnych w wielu wiadomościach, np. przyimków [10]. Podobnie jak przy wektoryzacji zliczającej słowa, tutaj także liczba najpopularniejszych słów - N- była wybierana eksperymentalnie.

Z wiadomości pobrano następujące cechy:

- `body_length` - długość tekstu wiadomości (w znakach),
- `tags_count` - liczba otwarć tagów HTML,
- `errors_count` - liczba błędnie zamkniętych tagów HTML,
- `cov_b` - pokrycie tekstu tagiem `<b>`,
- `cov_i` - pokrycie tekstu tagiem `<i>`,
- `cov_font` - pokrycie tekstu tagiem `<font>`,
- `cov_center` - pokrycie tekstu tagiem `<center>`,
- `http_links` - liczba linków HTTP w wiadomości,
- `http_raw_links` - liczba linków HTTP w wiadomości, których adres jest podany jako IP,
- `mail_links` - liczba linków mailowych w wiadomości,
- `attached_images` - liczba obrazków dołączony do wiadomości,

- `charset_errors` - wartość logiczna, oznacza występowanie błędów odczytu wiadomości w zadeklarowanej przez nią stronie kodowej,
- zwektoryzowany temat wiadomości,
- zwektoryzowana treść wiadomości.

Część cech zostało wyznaczonych w stosunku do długości tekstu wiadomości:

- `rel_tags_count` - stosunek `tags_count` do `body_length`,
- `rel_errors_count` - stosunek `errors_count` do `body_length`,
- `rel_cov_b` - stosunek `cov_b` do `body_length`,
- `rel_cov_i` - stosunek `cov_i` do `body_length`,
- `rel_cov_font` - stosunek `cov_font` do `body_length`,
- `rel_cov_center` - stosunek `cov_center` do `body_length`,
- `rel_http_links` - stosunek `http_links` do `body_length`,
- `rel_http_raw_links` - stosunek `http_raw_links` do `body_length`,
- `rel_mail_links` - stosunek `mail_links` do `body_length`.

Przykładową listę cech zamieszczono w listingu 2.9.

```
body_length                                                    1402
tags_count                                                       93
errors_count                                                     10
cov_b                                                           829
cov_i                                                            48
cov_font                                                       1315
cov_center                                                        0
http_links                                                        2
http_raw_links                                                    0
mail_links                                                        2
attached_images                                                   0
charset_errors                                                    0
rel_tags_count                                           0.06633381
rel_errors_count                                        0.007132668
rel_cov_b                                                 0.5912982
rel_cov_i                                                 0.0342368
rel_cov_font                                              0.9379458
rel_cov_center                                                    0
rel_http_links                                          0.001426534
rel_http_raw_links                                                0
rel_mail_links                                          0.001426534
```

Listing 2.9. *Lista cech przykładowej wiadomości (nie zawarto cech uzyskanych poprzez wektoryzację tematu i tekstu wiadomości)*

2.8 Przygotowanie danych wejściowych dla klasyfikatorów

W uczeniu maszynowym, często stosuje się normalizację danych wejściowych. Ma to celu zwiększenie skuteczności działania systemów uczących się. W tym przypadku zastosowano skalowanie wartości cech do zakresu `[0, 1]`. Taki typ i zakres normalizacji został wybrany ze względu na to, że produktem procesu wektoryzacji tekstu są macierze rzadkie, z wartościami nie mniejszymi niż 0. Taki proces normalizacji nie zaburzy rzadkości macierzy, co z kolei ułatwi przetrzymywanie takiej macierzy w pamięci operacyjnej.

3 Algorytmy uczenia maszynowego

Po odczytaniu wiadomości i ekstrakcji ich cech można przejść do procesu uczenia. Problem rozpoznawania spamu jest problemem klasyfikacji, tj. sytuacji w której system uczy się rozróżniać, do której z dwóch lub więcej kategorii należy przedstawiany mu przykład (w tym przypadku przykładami są wiadomości). Dla tworzonego filtra istnieć będą 2 kategorie: wiadomość niespamowa i spam. W rozdziale tym przedstawione zostały algorytmy zajmujące się klasyfikacją, są to:

- regresja logistyczna,
- naiwny klasyfikator bayesowski,
- maszyna wsparcia wektorowego,
- las drzew losowych.

3.1 Kroswalidacja

W celu uzyskania miarodajnych wyników podczas testowania algorytmów uczenia maszynowego, wszystkie pomiary wydajności należy wykonywać na innym zestawie danych, niż te użyte do treningu. W tym celu, korpus wiadomości został podzielony na zestaw treningowy i zestaw testowy według poniższych reguł:

1. Cały korpus zostaje podzielony na k równych części, przy czym w każdej części proporcja wiadomości spamowych i niespamowych jest taka sama.
2. Walidacja zostaje wykonana k razy.
3. W każdej walidacji $k-1$ części zostaje wykorzystanych jako dane treningowe, a pozostała część jako dane testowe.
4. Wyniki powyższych walidacji zostają uśrednione.

3.2 Krzywa ROC

Krzywa ROC (ang. *receiver operator characteristic*) jest techniką wizualizacji wydajności klasyfikatora. Technika ta wykorzystywana jest głównie w teorii detekcji sygnałów, znalazła zastosowanie również w uczeniu maszynowym. Krzywa taka opisuje trafność klasyfikacji w zależności od progu decyzyjnego. Tworzona jest poprzez wyznaczanie liczby przykładów, które zostały poprawnie zakwalifikowane jako należące do rozważanej klasy (TPR, ang. *true positive rate*) oraz liczby przykładów, które zostały błędnie zakwalifikowane jako należące do klasy (FPR, ang. *false positive rate*) dla różnych progów decyzyjnych.

W celu uzyskania skalarnej miary wydajności liczone jest pole pod krzywą, miara taka nosi nazwę AUC (ang. *Area Under Curve*). Im większa wartość AUC, tym lepszy wynik osiągnięty przez klasyfikator.

3.3 Dobór parametrów wektoryzacji

Jak wspomniano wcześniej, liczba najpopularniejszych słów branych pod uwagę, w temacie wiadomości i jej tekście, została wybrana eksperymentalnie. Do testów wykorzystano regresję logistyczną o domyślnych parametrach (więcej o tym algorytmie w dalszej części tego rozdziału). Wyniki pomiarów zamieszczono w tabeli 3.1 i rysunku 3.1. W dalszej części pracy zdecydowano się wykorzystać parametry: `text_words=2000, subject_words=300`. Przy tych parametrach osiągnięto wysoką wydajność, natomiast dalsze zwiększanie wartości tych parametrów powodowałoby wydłużenie czasów treningu systemu i klasyfikacji wiadomości.

Tabela 3.1. *Wyniki kroswalidacji dla doboru paramerów wektoryzacji; parametr* `text_words` *oznacza liczbę słów w tekście wiadomości, natomiast* `subject_words` *- liczbę słów w temacie wiadomości*

Parametry	Średnie AUC	Odchylenie standardowe
text_words=500, subject_words=10	0.99701	0.00052
text_words=500, subject_words=100	0.99754	0.00054
text_words=500, subject_words=300	0.99766	0.00054
text_words=1000, subject_words=10	0.99813	0.00055
text_words=1000, subject_words=100	0.99834	0.00053
text_words=1000, subject_words=300	0.99838	0.00052
text_words=2000, subject_words=10	0.99857	0.00054
text_words=2000, subject_words=100	0.99861	0.00062
text_words=3000, subject_words=10	0.99868	0.00045
text_words=2000, subject_words=300	0.99870	0.00056
text_words=3000, subject_words=100	0.99878	0.00053
text_words=3000, subject_words=300	0.99885	0.00051

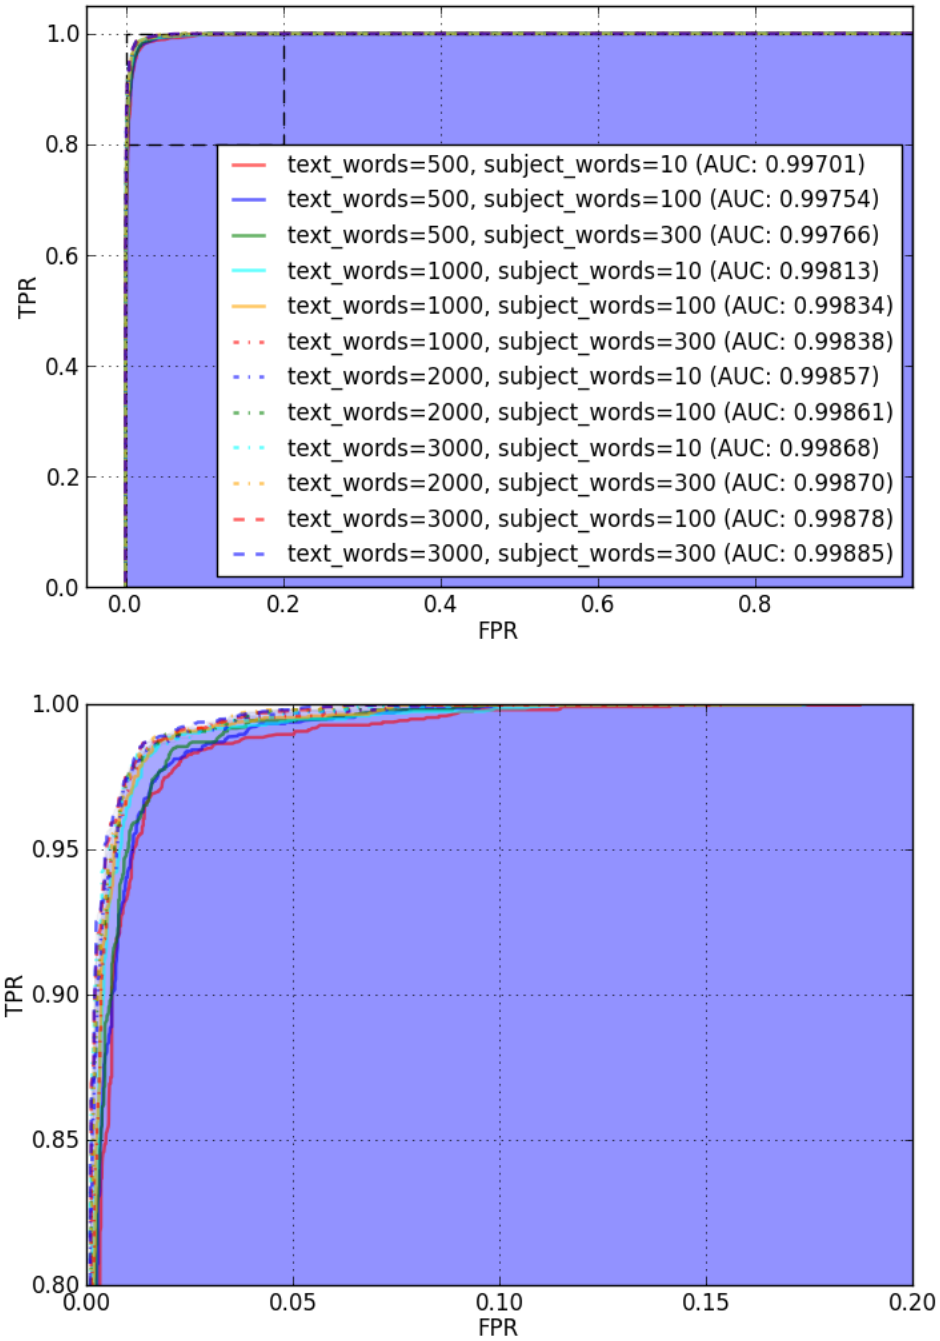

Rysunek 3.1. *Krzywe ROC kroswalidacji dla wyboru parametrów wektoryzacji*

3.4 Regresja logistyczna

Regresja logistyczna jest uogólnionym modelem liniowym klasyfikacji danych. Dzięki wykorzystaniu funkcji logistycznej, wartość przewidywana przez ten model zawiera się w przedziale `[0, 1]` [11].

Jednym z parametrów regresji logistycznej jakim można manipulować jest `C`. Parametr ten odpowiedzialny jest za regularyzację. Regularyzacja ma na celu zapobieganie sytuacji, w której algorytm nadmiernie dopasuje (ang. *overfitting*) się do danych treningowych, co obniży jego efektywność dla danych testowych [11]. Im mniejsza wartość `C`, tym regularyzacja będzie silniejsza.

Tabela 3.2 i rysunek 3.2 przedstawiają wyniki kroswalidacji dla regresji logistycznej z użyciem różnych wartości parametru `C`. Z wyników tych można wywnioskować, że optymalna wartość `C` zawiera się wa zakresie `[3.5, 7.5]`. Przeciętny czas treningu wyniósł 30 sekund.

Tabela 3.2. *Wyniki kroswalidacji dla regresji logistycznej*

Parametry	Średnie AUC	Odchylenie standardowe AUC	TPR dla FPR ~ 0.03
C=0.1	0.99748	0.00059	0.98969
C=0.5	0.99851	0.00058	0.99209
C=1.0	0.99871	0.00055	0.99209
C=1.5	0.99877	0.00057	0.99156
C=7.5	0.99882	0.00059	0.99330
C=5.0	0.99883	0.00059	0.99307
C=3.5	0.99883	0.00058	0.99352

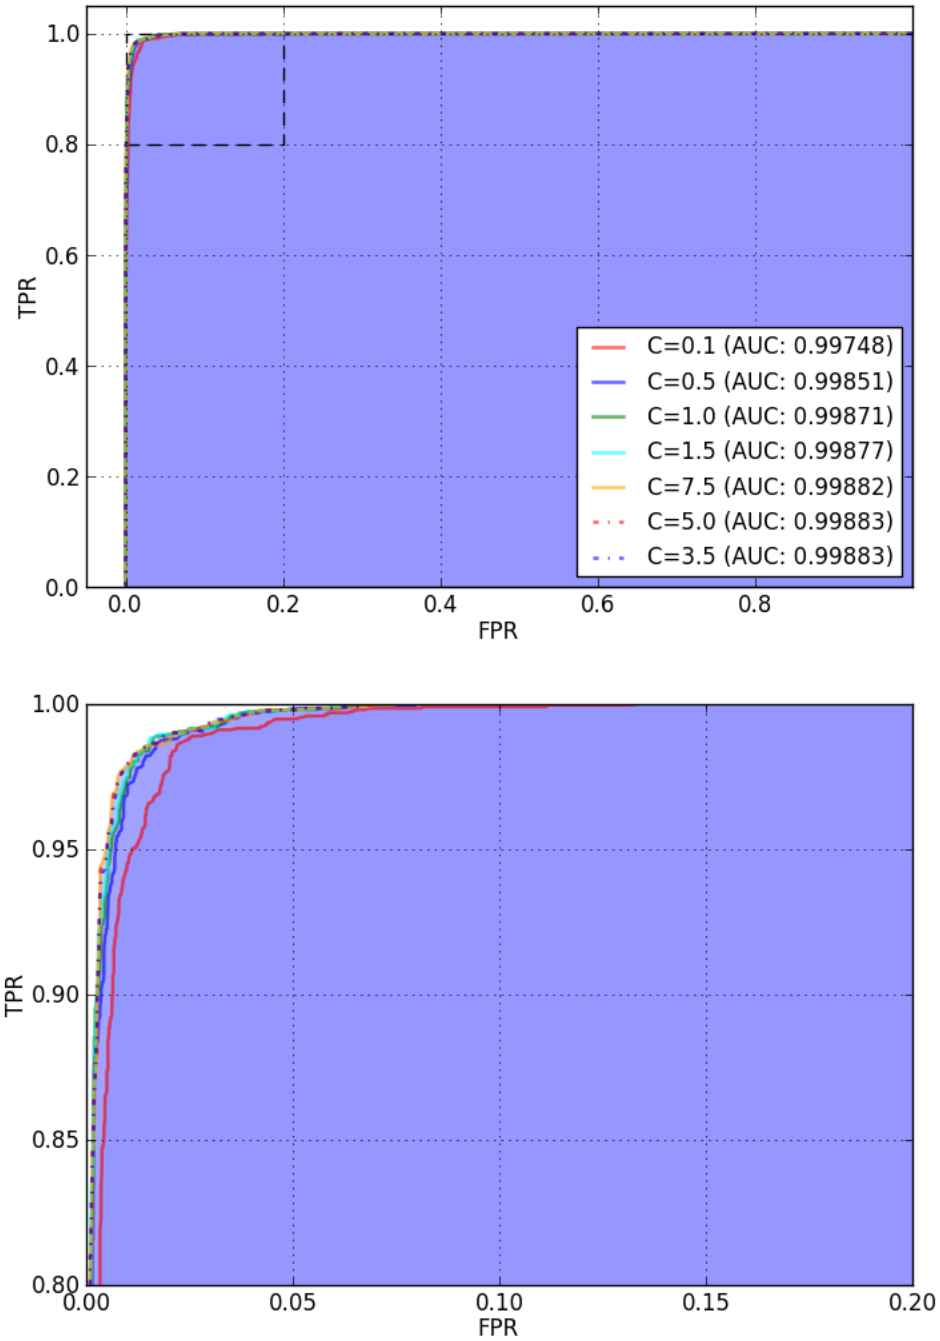

Rysunek 3.2. *Krzywe ROC dla regresji logistycznej*

3.5 Naiwny klasyfikator bayesowski

Klasyfikator bayesowski jest techniką uczenia maszynowego stosującą twierdzenie Bayesa do przetwarzanych danych. Nazywa się go naiwnym, ponieważ zakłada on, że wszystkie przetwarzane cechy są od siebie niezależne. Mimo, że założenie to zwykle nie jest spełnione, algorytm wciąż jest skuteczny [11].

Parametrem, jaki można kontrolować jest tutaj wygładzanie Laplace'a - `alpha`. Wyniki kroswalidacji znajdują się w tabeli 3.3 i na rysunku 3.3. Średni czas treningu wynosił 25 sekund.

Tabela 3.3. *Wyniki kroswalidacji dla naiwnego klasyfikatora bayesowskiego*

Parametry	Średnie AUC	Odchylenie standardowe AUC	TPR dla FPR ~ 0.03
alpha=1.0	0.99580	0.00104	0.97942
alpha=0.001	0.99585	0.00152	0.98065
alpha=0.5	0.99602	0.00100	0.98102
alpha=0.01	0.99613	0.00123	0.98189
alpha=0.1	0.99621	0.00105	0.98254

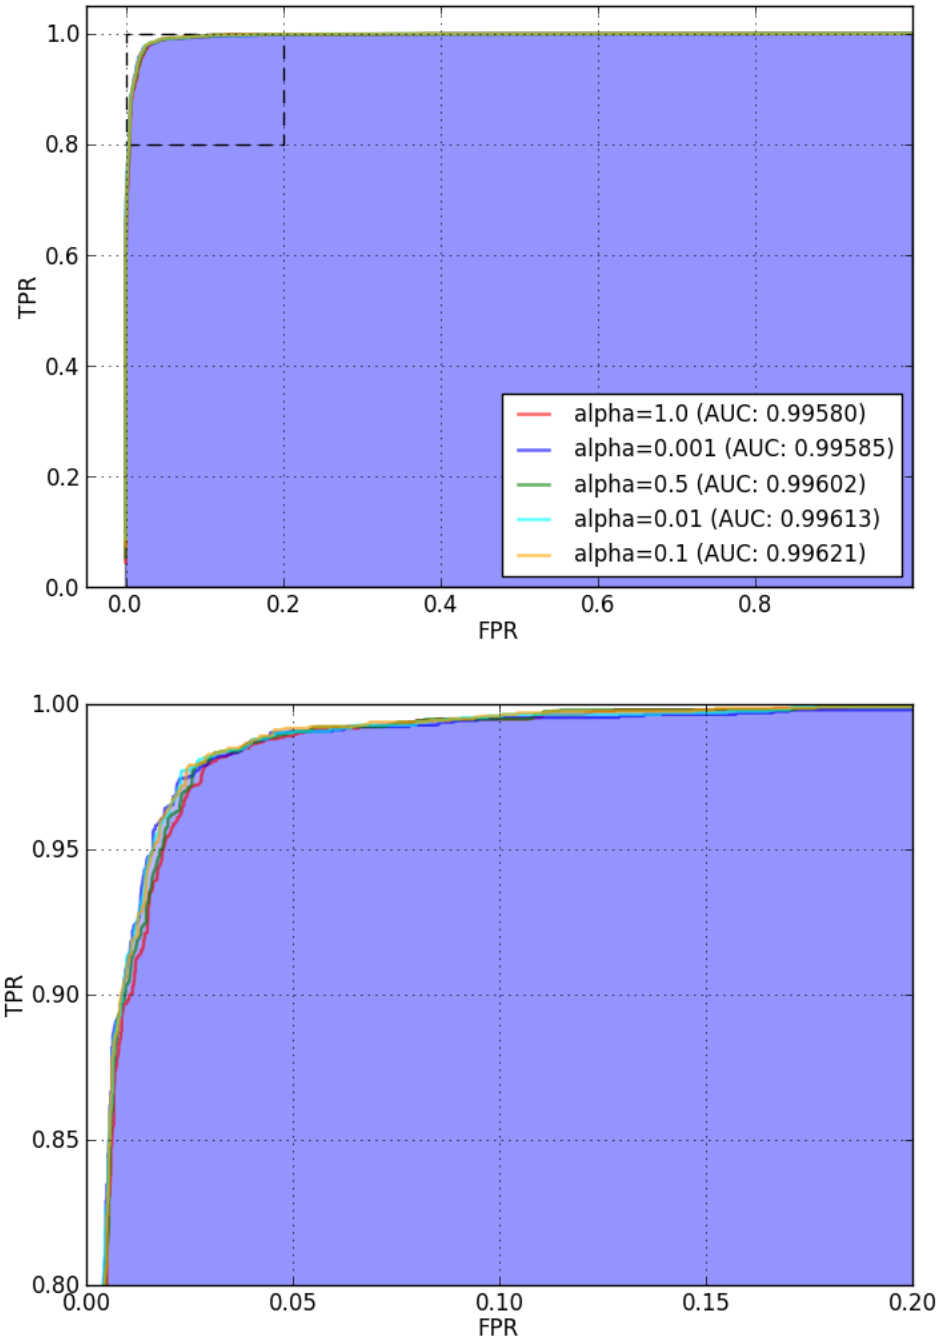

Rysunek 3.3. *Krzywe ROC dla naiwnego klasyfikatora bayesowskiego*

3.6 Maszyna wsparcia wektorowego

Podobnie jak regresja logistyczna, maszyna wsparcia wektorowego (ang. SVM - *Support Vector Machine*) jest uogólnionym modelem liniowym klasyfikacji. SVM reprezentuje dane jako punkty w przestrzeni (wymiar tej przestrzeni jest równy liczbie cech danych wejściowych). Celem algorytmu jest rozdzielenie przykładów należących do różnych kategorii, za pomocą hiperpłaszczyzny, będącej w największym możliwym odstępie od punktów, które oddziela (przykład takiego podziału znajduje się na rysunku 3.3). Ponadto, dzięki zastosowaniu funkcji jąder, SVM może zostać zastosowany do nieliniowej klasyfikacji [11].

Przetestowane zostały dwie wersje SVM:

- liniowy SVM (bez funkcji jądra); wyniki w tabeli 3.3 i na rysunku 3.4,
- SVM z jądrem RBF (ang. *Radial Basis Function*), parametrem funkcji jądra jest `sigma`; wyniki w tabeli 3.4 i na rysunku 3.5.

Podobnie jak w regresji logistycznej, parametrem jest tu `C`, odpowiedzialne za regularyzacje. Ze względu na długi czas obliczeń, zdecydowano się zmniejszyć parametry wektoryzacji, zastosowano: `text_words=500, subject_words=50`. Przeciętny czas treningu wyniósł:

- 2.2 minuty dla SVM z jądrem RBF,
- 1.2 minuty dla liniowego SVM.

Tabela 3.3. *Wyniki kroswalidacji dla liniowego SVM*

Parametry	Średnie AUC	Odchylenie standardowe AUC	TPR dla FPR ~ 0.03
C=3.5	0.99500	0.00059	0.97272
C=1.5	0.99603	0.00050	0.98154
C=1.0	0.99639	0.00046	0.98312
C=0.1	0.99673	0.00074	0.98470
C=0.5	0.99677	0.00043	0.98734

Tabela 3.4. *Wyniki kroswalidacji dla SVM z jądrem RBF*

Parametry	Średnie AUC	Odchylenie standardowe AUC	TPR dla FPR ~ 0.03
gamma=0.01, C=0.1	0.97849	0.00334	0.67879
gamma=0.01, C=0.5	0.99052	0.00154	0.91274
gamma=0.1, C=0.1	0.99224	0.00129	0.93476
gamma=0.01, C=1.0	0.99418	0.00101	0.95511
gamma=0.01, C=1.5	0.99524	0.00074	0.96782
gamma=0.01, C=3.5	0.99622	0.00037	0.98575
gamma=0.1, C=0.5	0.99647	0.00038	0.98523
gamma=0.1, C=1.0	0.99679	0.00026	0.98839
gamma=0.1, C=3.5	0.99698	0.00060	0.98681
gamma=0.1, C=1.5	0.99700	0.00032	0.98786

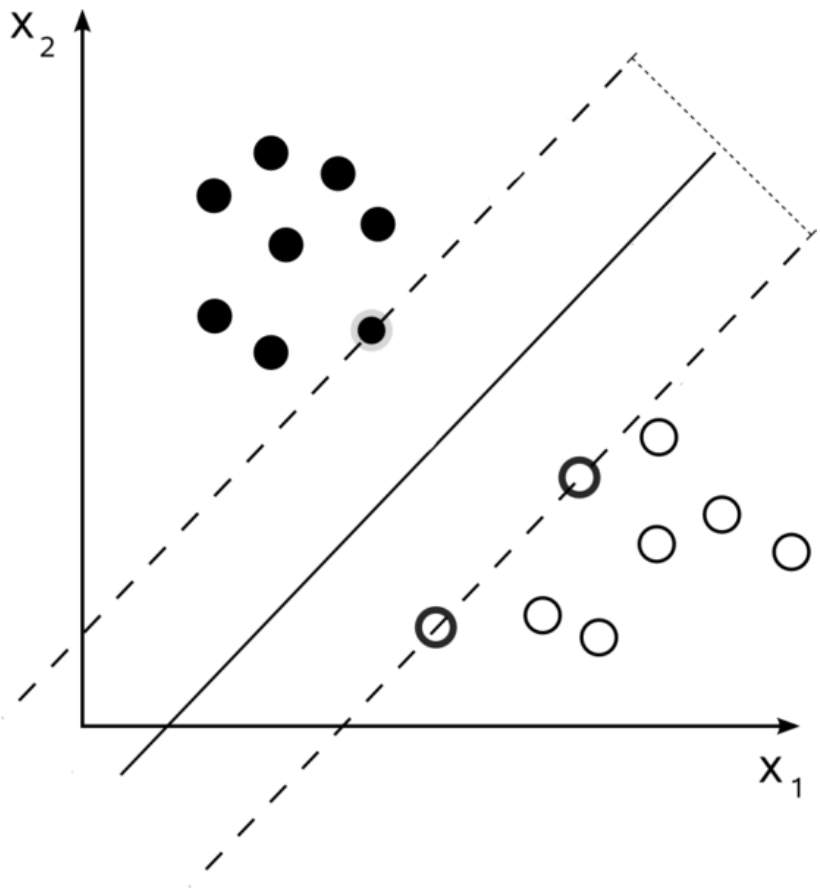

Rysunek 3.3. *Przykład rodzielenia dwóch kategorii danych przez SVM [12]*

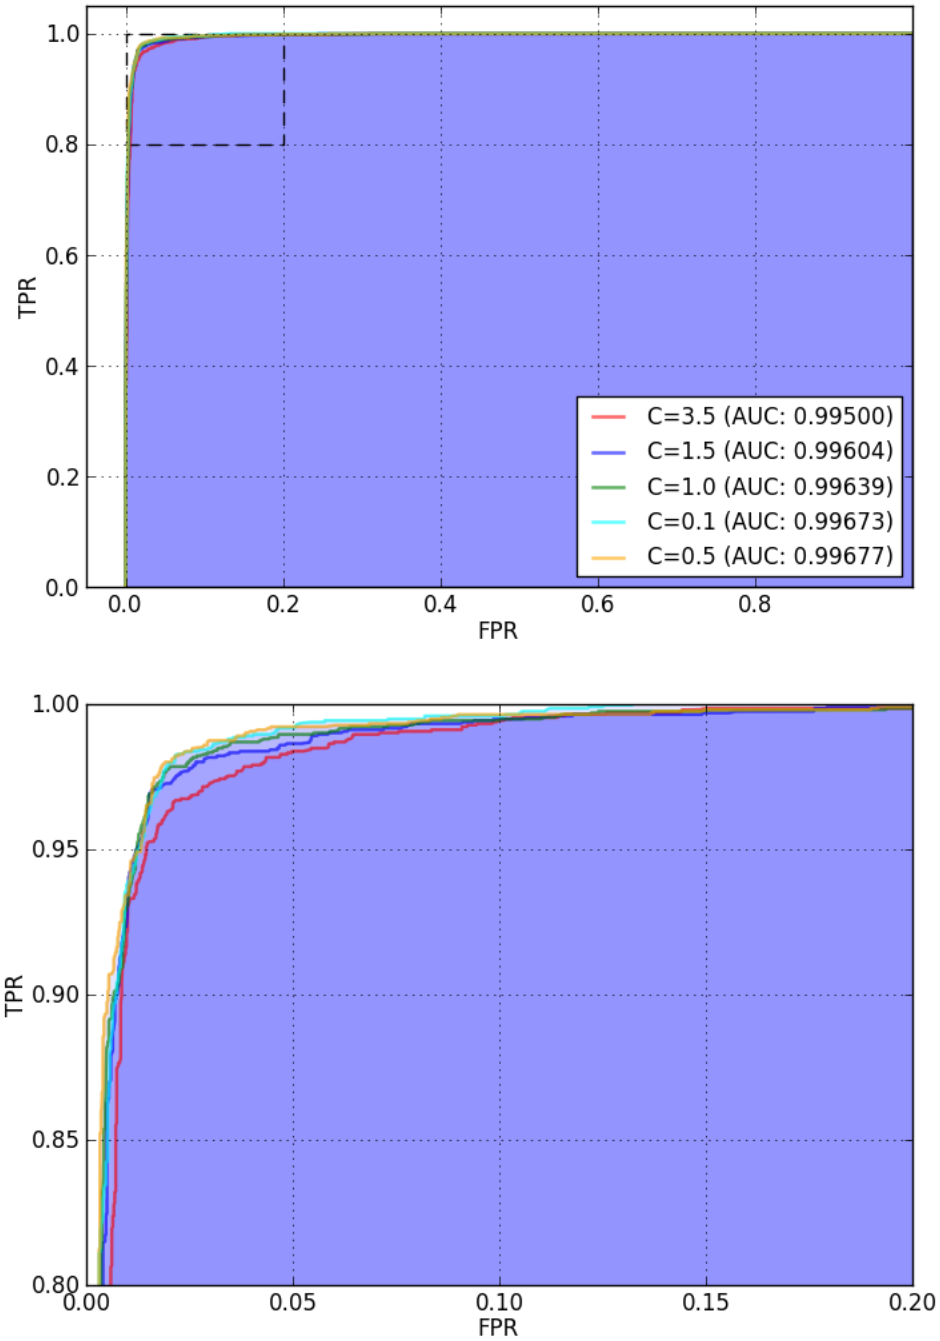

Rysunek 3.4. *Krzywe ROC dla liniowego SVM*

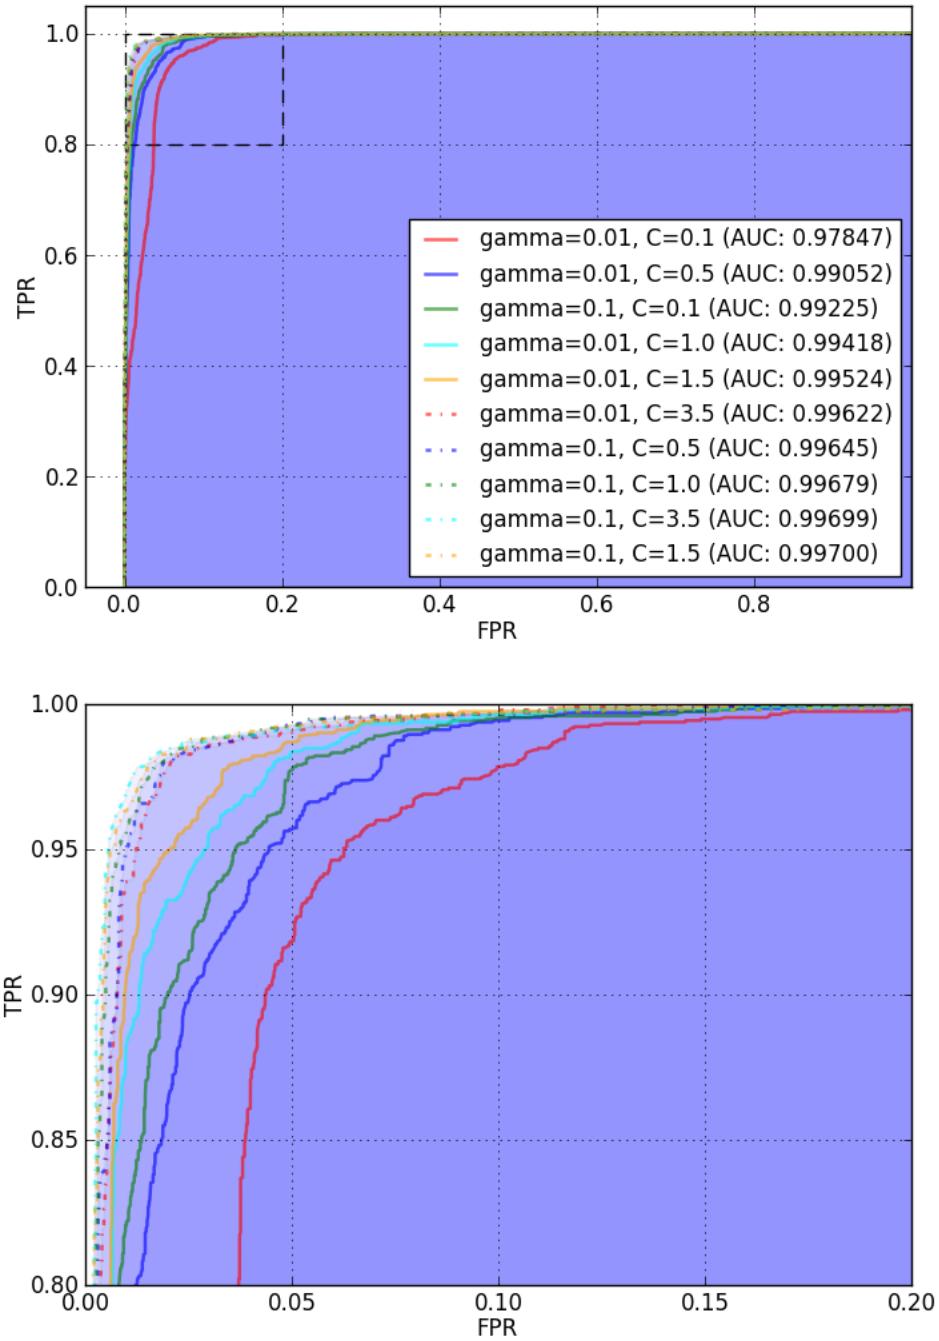

Rysunek 3.5. *Krzywe ROC dla SVM z jądrem RBF*

3.7 Las drzew losowych

Las drzew losowych jest metodą zespołowego uczenia. Polega ona na wytrenowaniu wielu prostych, prawdopodobnie słabo przystosowanych klasyfikatorów i połączenia ich w jeden klasyfikator. W przypadku drzew losowych, jako klasyfikatory wykorzystywane są drzewa decyzyjne. Świetnie nadają się do tego zadania, ze względu na ich możliwość uczenia się skomplikowanych relacji między cechami [11].

W przypadku lasów losowych można decydować z ilu drzew składać się będzie las, odpowiedzialny jest za to parametr `n_estimators`. Efektywność lasów, w zależności od liczby drzew przedstawiono w tabeli 3.5 i na rysunku 3.6.

Wartą odnotowania zaletą drzew losowych jest fakt, że zarówno trening, jak i późniejsza klasyfikacja, mogą zostać zrównoleglone. Może to znacząco poprawić szybkość działania na maszynach wielordzeniowych i klastrach obliczeniowych. Czas treningu, zależnie od liczby użytych drzew, wynosił od 23 do 35 sekund.

Tabela 3.5. *Wyniki kroswalidacji dla lasów drzew losowych*

Parametry	Średnie AUC	Odchylenie standardowe AUC	TPR dla FPR ~ 0.03
n_estimators=10	0.99503	0.00170	0.97215
n_estimators=30	0.99713	0.00058	0.98681
n_estimators=50	0.99741	0.00045	0.98857
n_estimators=100	0.99755	0.00069	0.98892
n_estimators=75	0.99774	0.00044	0.98892

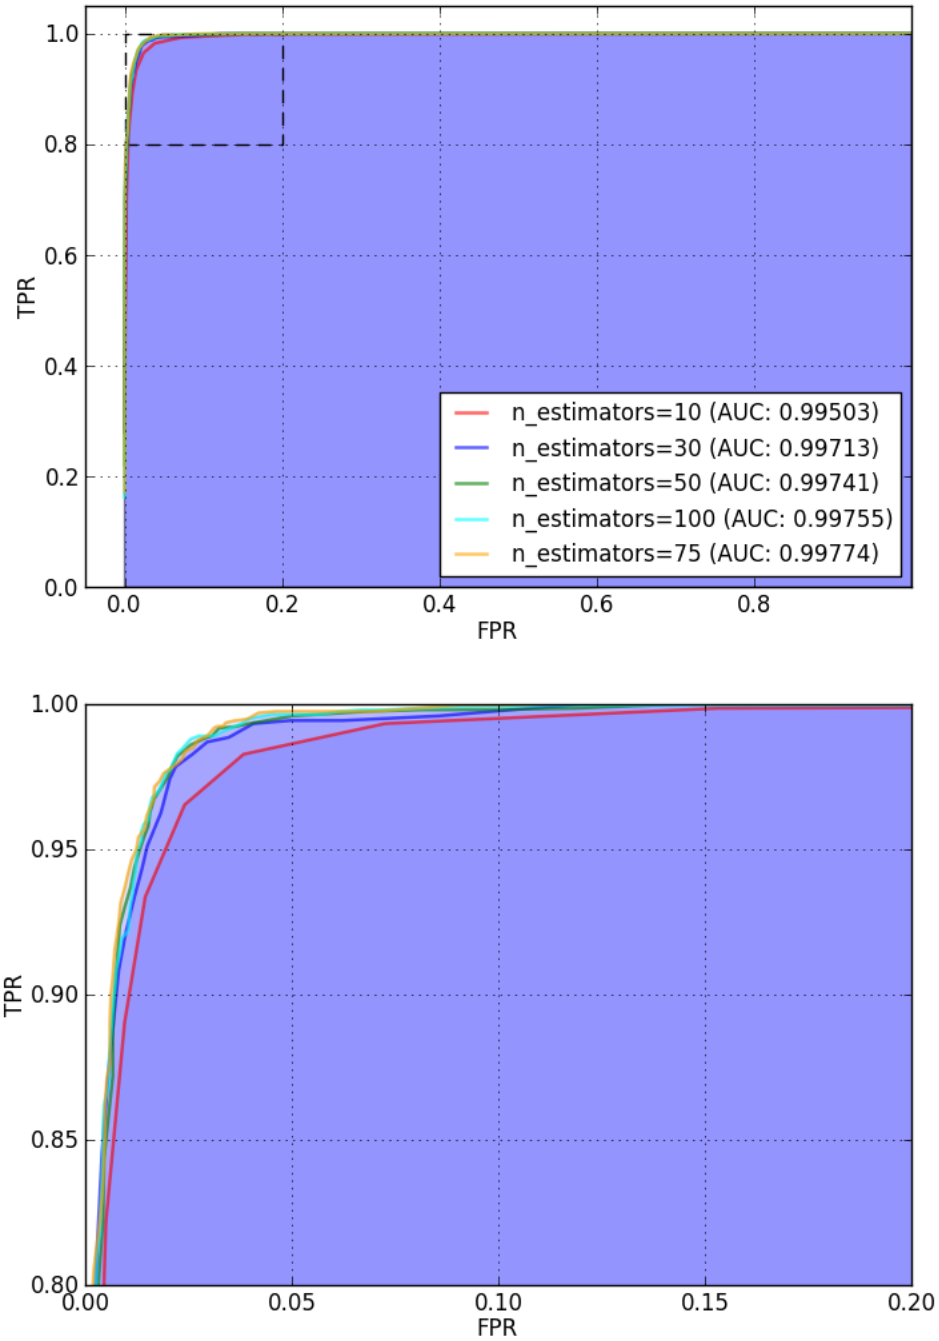

Rysunek 3.6. *Krzywa ROC dla lasu drzew losowych*

3.8 Porównanie efektywności klasyfikatorów

W finalnym porównaniu zamieszczono instancje poszczególnych algorytmów, które uzyskały najwyższy wynik TPR, dla FPR bliskiego 0.03. Pozwala to wybrać algorytm (i jego parametry), który najlepiej wykrywa spam, przy założeniu, że poziom fałszywych alarmów jest na poziomie około 3%. Najlepszy rezultat - wśród porównywanych algorytmów - uzyskała regresja logistyczna. Pozostałe algorytmy uzyskały zbliżone do siebie wyniki. Lepszy wynik mogłaby uzyskać maszyna wsparcia wektorowego, jednakże, ze względu na długi czas obliczeń, algorytm ten pracował na mniejszej ilości danych (zmniejszenie parametrów wektoryzacji tekstu). Szczegółowe porównanie znajduje się w tabeli 3.6 i na rysunku 3.7.

Tabela 3.6. *Porównawczy wynik wszystkich testowanych algorytmów*

Algorytm	Parametry	Średnie AUC	Odchylenie standardowe AUC	TPR dla FPR ~ 0.03
Regresja logistyczna	C=3.5	0.99883	0.00058	0.99352
Naiwny klas. bayesowski	alpha=0.1	0.99621	0.00105	0.98254
SVM (liniowy)	C=0.5	0.99677	0.00043	0.98734
SVM (RBF)	gamma=0.1, C=1.0	0.99679	0.00026	0.98839
Las drzew losowych	n_estimators=75	0.99774	0.00044	0.98892

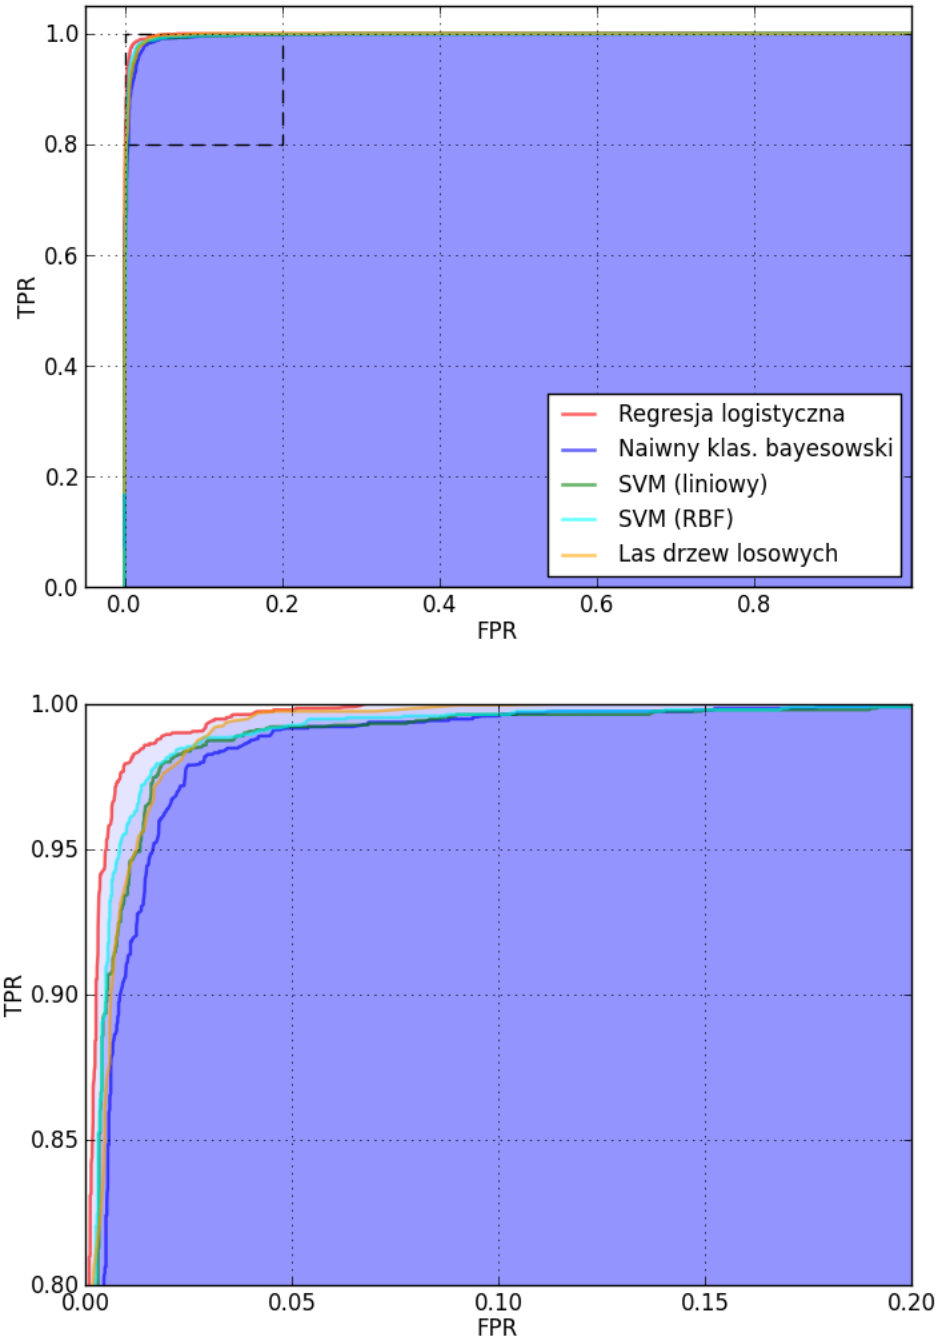

Rysunek 3.7. *Zbiór krzywych ROC poszczególnych algorytmów*

4 Integracja z programem pocztowym

Aby filtr antyspamowy mógł zostać zostać wykorzystany do ochrony skrzynek użytkowników przed niechcianymi wiadomościami, musi mieć on możliwość współpracy z programami pocztowymi. W dalszej części tego rozdziału zaprezentowany został protokół używany przez tworzony w tej pracy filtr antyspamowy. Zademonstrowano również przykładowe rozszerzenie dla programu pocztowego, korzystające z tego protokołu.

4.1 Protokół komunikacji

Założeniem projektu było umożliwienie dowolnemu klientowi poczty na korzystanie z filtra antyspamowego. W tym celu zastosowano komunikację bazującą na protokole sieciowym, a dokładniej protokole HTTP. Klient chcąc sprawdzić czy dana wiadomość jest spamem, wysyła ją do serwera HTTP filtra antyspamowego, a w odpowiedzi otrzymuje wartość logiczną (prawda lub fałsz) mówiącą, czy wiadomość została uznana za spam.

Serwer działa na porcie `2220`. Oczekuje na wiadomości w formie surowej, wysłane z użyciem metody `PUT` [13] protokołu HTTP. Po otrzymaniu takiej wiadomości serwer podejmuje następujące działania:

1. Parsuje surową wiadomość korzystając z opisanego wcześniej parsera wiadomości.
2. Przekazuje sparsowaną wiadomość do ekstraktora cech.
3. Dane otrzymane z ekstraktora cech zostają przekazane do wytrenowanego wcześniej algorytmu uczenia maszynowego.
4. Jeśli algorytm uzna wiadomość za spam, serwer zwróci pustą odpowiedź z kodem HTTP `221`, w przeciwnym wypadku zwróci pustą odpowiedź z kodem `220`.

4.2 Wtyczka do klienta poczty

Claws Mail jest prostym klientem poczty elektronicznej przeznaczonym zarówno na systemy operacyjne z rodziny Windows jaki i Unix.

Został on wykorzystany w tej pracy, ze względu na możliwość wykonywania przez niego skryptów języka Python. Skrypt taki w trakcie wykonania uzyskuje dostęp do okna programu i znajdujących się w nim wiadomości i folderów. Z użyciem tego mechanizmu wykonana została integracja klienta poczty z filtrem antyspamowym (a dokładniej jego serwerem HTTP). Po uruchomieniu skrypt wykonuje następujące kroki:

1. W API klienta uzyskuje dostęp do aktualnie wybranego folderu i znajduje w nim wszystkie nieprzeczytane wiadomości.
2. Dla każdej nieprzeczytanej wiadomości odczytany zostaje plik zawierający e-mail w postaci surowej.
3. Każda surowa wiadomość zostaje wysłana osobno, za pomocą protokołu HTTP, metodą `PUT`, na adres `127.0.0.1`, port `2220`.
4. Skrypt oczekuje na odpowiedź od serwera, jeśli w odpowiedzi otrzyma kod HTTP `221` wiadomość zostaje uznana za spam i przeniesiona do folderu "Kosz".
5. Po sprawdzeniu wszystkich wiadomości wyświetlone zostaje podsumowanie o liczbie wiadomości, które zostały rozpoznane jako spam.

Uruchomienie i efekt działania skryptu widoczne są na rysunkach 4.1 i 4.2.

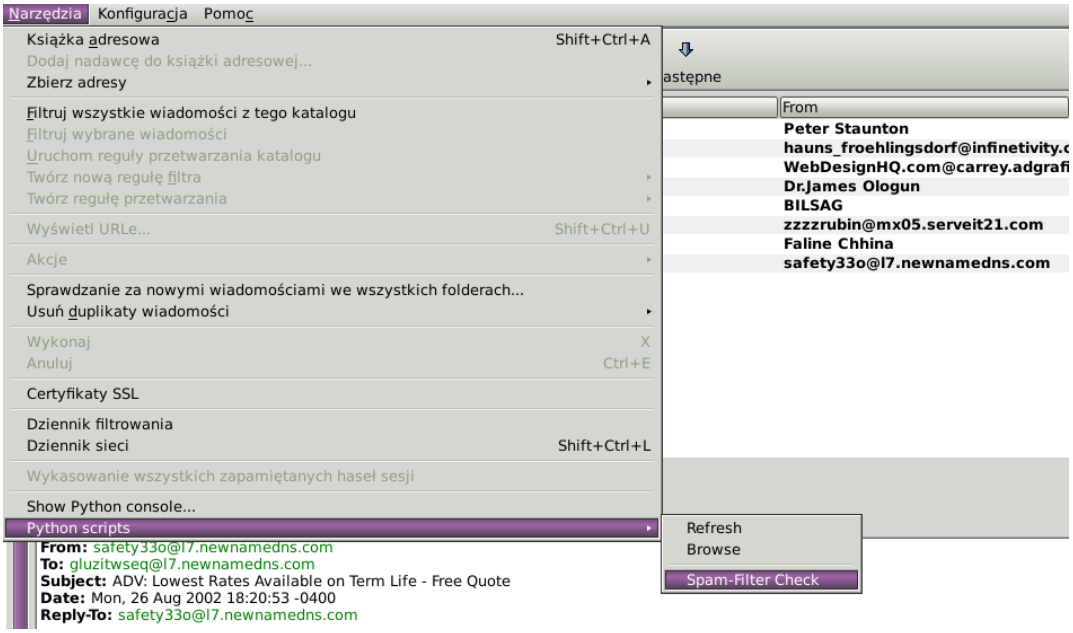

Rysunek 4.1. *Wywołanie skryptu sprawdzającego wiadomości e-mail*

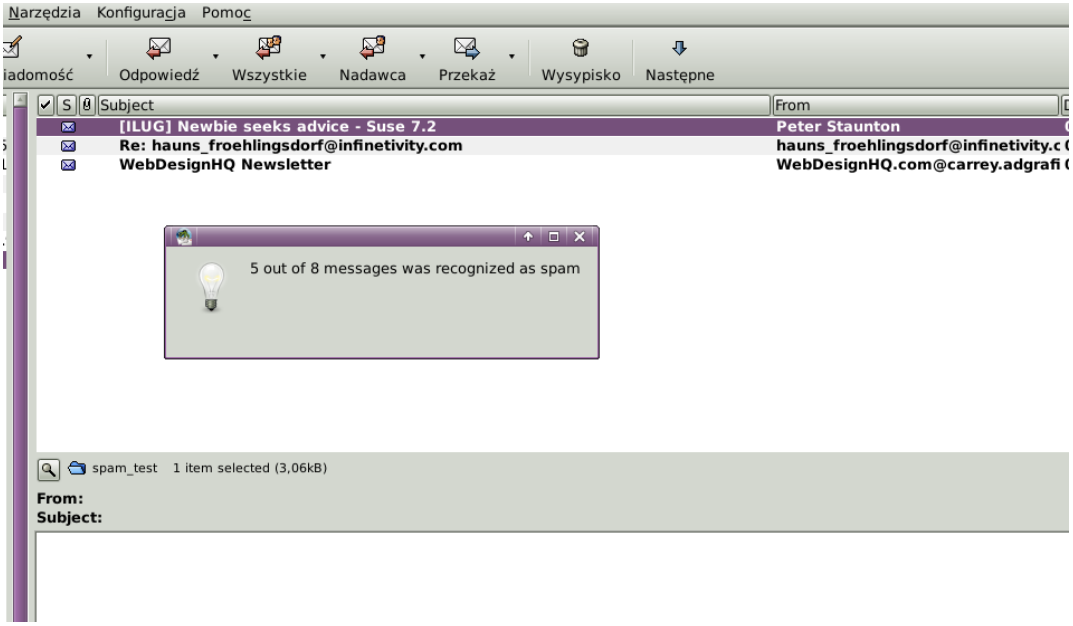

Rysunek 4.2. *Efekt działania skryptu sprawdzającego wiadomości e-mail*

5 Podsumowanie i możliwości rozbudowy

Efektem pracy jest kompletny system filtra antyspamowego. Udało się stworzyć filtr skutecznie wykrywający wiadomości spamowe. Filtr obserwuje takie cechy wiadomości jak użyte słowa, czy procentowe pokrycie tekstu tagami HTML. Wszystkie przetestowane algorytmy uczenia maszynowego udało się wytrenować z zadowalającymi rezultatami. Każdy z nich mógłby zostać wykorzystany w filtrze antyspamowym. Najskuteczniejszym z testowanych algorytmów, przy cechach wiadomości wybranych w tej pracy, okazała się regresja logistyczna.

Oprócz samego klasyfikatora, stworzone zostały narzędzia wspomagające pracę filtra. Jednym z tych narzędzi jest parser surowych wiadomości e-mail. Potrafi on skutecznie przetwarzać wiadomości wieloczęściowe, korzystające z HTML, wykorzystujące różne kodowania, zapisane w różnych stronach kodowych i zawierające załączniki.

Innym narzędziem, pozwalającym na integrację z programami pocztowymi, jest wbudowany w filtr serwer HTTP. Serwer ten służy do odbierania wiadomości, które mają zostać sprawdzone. Do przetestowania działania serwera stworzona została prosta wtyczka do klienta poczty *Claws-Mail*.

W przypadku dalszego rozwoju, warto rozważyć szukanie i tworzenie nowych cech wiadomości, a także przetestowanie innych algorytmów uczenia maszynowego. Godnym uwagi jest również zastosowanie stemmingu [14] do przetworzenia słów wiadomości do formy podstawowej. W przypadku rozbudowy parsera wiadomości, warto rozważyć implementacje skuteczniejszego parsowania treści HTML, a dokładniej użytych w nich arkuszy stylów CSS (ang. *Cascade Style Sheet*). Innym obiecującym rozszerzeniem możliwości jest odczytywanie załączników wiadomości. Ma to zastosowanie w przypadkach kiedy spamer próbuje oszukać filtr, poprzez umieszczenie właściwej wiadomości np. w pliku PDF (ang. *Portable Document Format*). W przypadku serwera HTTP warto zastanowić się nad rozbudową protokołu komunikacyjnego. Obecnie pozwala na wysłanie tylko jednej wiadomości w jednym zapytaniu HTTP. W przypadku wykorzystania filtra w środowisku gdzie wiele wiadomości sprawdzanych byłoby jednocześnie, warto tą funkcję rozbudować.

6 Bibliografia

1. Bolc L., Zaremba P., Wprowadzenie do uczenia się maszyn, Akademicka Oficyna Wydawnicza, 1993
2. http://scikit-learn.org/
3. http://www.csie.ntu.edu.tw/~cjlin/liblinear/
4. http://www.csie.ntu.edu.tw/~cjlin/libsvm/
5. http://docs.python.org/2/library/htmlparser.html
6. http://scikit-learn.org/stable/modules/feature_extraction.html
7. http://www.claws-mail.org/
8. http://spamassassin.apache.org/
9. http://spamassassin.apache.org/publiccorpus/readme.html
10. Manning, C. D.; Raghavan, P.; Schutze, H. (2008). "Scoring, term weighting, and the vector space model"
11. Trevor Hastie, Robert Tibshirani, Jerome Friedman, The Elements of Statistical Learning, 2009
12. http://en.wikipedia.org/wiki/Support_vector_machine
13. http://www.w3.org/Protocols/rfc2616/rfc2616-sec9.html Sekcja 9.6.
14. http://en.wikipedia.org/wiki/Stemming